2024.2.14

신용카드 사기 거래 탐지

Unsupervised Anomaly Detection AI 모델 개발

FOM

Focus On Data Mining

INDEX

1.프로젝트 개요

2.데이터 특징

3. EDA(탐색적 데이터 분석)

4. 비지도 학습

1. 프로젝트 개요

주제 선정 배경

- 사기성 신용카드 거래를 탐지하여 고객이 구매하지 않은 항목에 대해 요금을 청구하지 않기 위한 도구 필요

1) 신용카드 사기거래 문제 심화

사회

"中 공항서 복제된 듯...180만원 뜯겨" 여행 유튜버도 당한 '황당 카드 사기'

경제

60평 아파트에 벤틀리·람보 타던 20대 알고보니 '2백억 카드깡'…카드사기 기승

크레딧카드 사기 급증, 소액 쓴 뒤 큰돈 청구

고성능 컴퓨터로 번호 훔쳐
아마존서 1달러 결제 시험
FTC "1분기만 15%나 증가"
성인 50% "피해 경험 있다"

2) 데이터 구축 시간 및 비용의 한계

-방대한 양의 거래 데이터에서 소수의 사기거래 발견 어려움.

-모든 데이터에 대하여 사기거래 여부 확인 및 Labeling에 큰 비용 소요.

1. 프로젝트 개요

프로젝트 목표 및 데이터

- 프로젝트 목적

-사기성 신용카드 거래 여부를 알 수 없는 방대한 데이터로부터 **사기 거래를 탐지하는 AI 를 개발 코드**를 구현

- 데이터 설명

1. 학습(Train) 데이터셋 (113842개)
   설명:**정상, 사기 거래의 여부를 알 수 없는(대부분 정상 거래) 신용 카드 데이터** (Unlabeled)

2. 검증(Validation) 데이터셋 (28462개)
   설명: **정상, 사기 거래의 여부가 포함된 신용 카드 데이터**
   Class : 신용 카드 거래의 정상, 사기 여부 (정상 : 0, 사기 : 1)

3. 테스트(Test) 데이터셋 (142503개)
   설명: 정상, 사기 거래의 여부를 알 수 없는(대부분 정상 거래) 신용 카드 데이터 (Unlabeled)

2. 데이터 특징

- 데이터 특징

  - validation data에 tain ,test 데이터에는 존재하지 않는 class(label)이 존재함.
  - train data에 label이 존재하지 않으므로, **비지도 학습**을 통해 모델의 패턴을 발견하고자 함.

V26	V27	V28	V29	V30	Class
0.094199	0.246219	0.083076	-0.255991	-0.994878	0
0.199964	0.016371	-0.014605	0.168937	-0.994784	0
0.048741	-0.053192	0.016251	0.169496	-0.994502	0

3. EDA(탐색적 데이터 분석)

데이터 시각화_ 히트맵 분포

히트맵 분포 (변수 간 상관관계 확인)

- 대부분의 변수들이 독립적인 패턴을 보이며, 변수 간 높은 상관관계가 없음.
- ID 변수의 경우 대부분의 특징과 관계 없음
- 상관관계가 높은 일부 변수는 차원 축소와 변수 제거를 고려해야함.

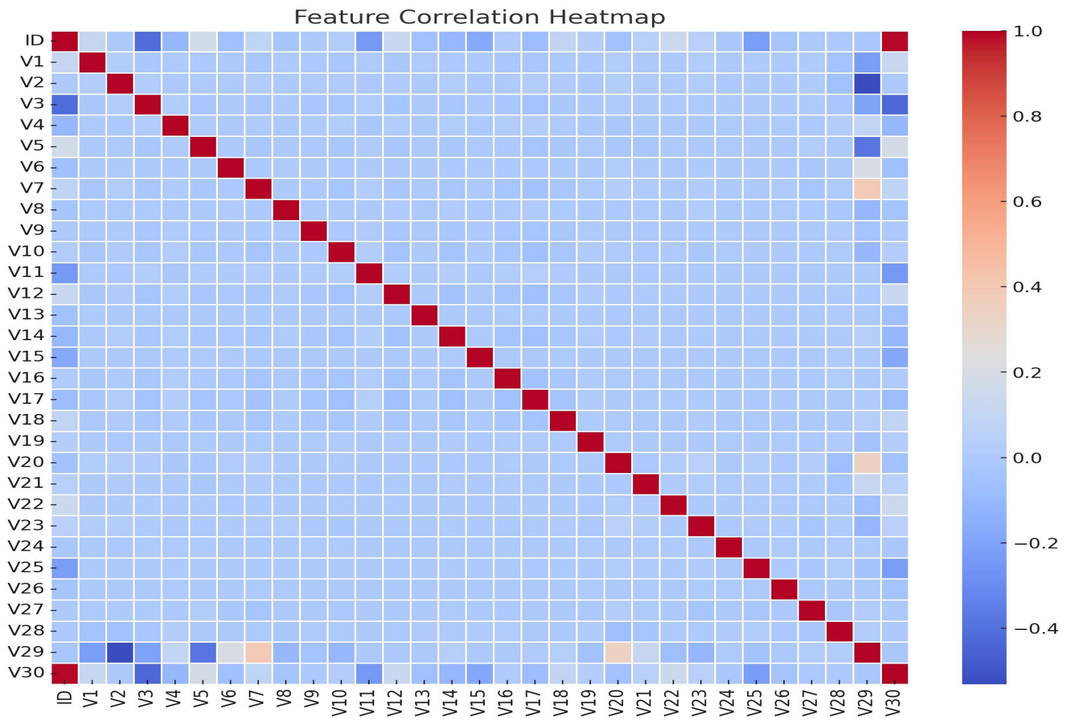

4. 비지도 학습

개념 및 필요성

- **비지도학습**

정의 : label이 지정되지 않은 데이터 세트 분석 및 클러스터링을 통해 패턴을 발견하도록 모델을 훈련함.
목적: 방대한 데이터로에서 패턴을 발견, 데이터 구조와 관계를 파악하는 것.
대표 알고리즘 :군집화, 차원 축소, 연관규칙 K-Means, PCA, DBSCAN, Autoencoder
활용 분야: 고객 군집화, 이상탐지, 자연어 처리 모델 등에 활용됨.

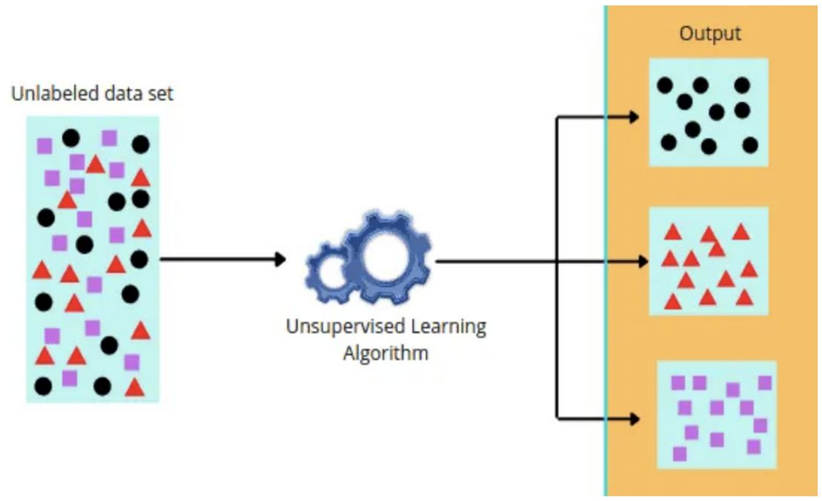

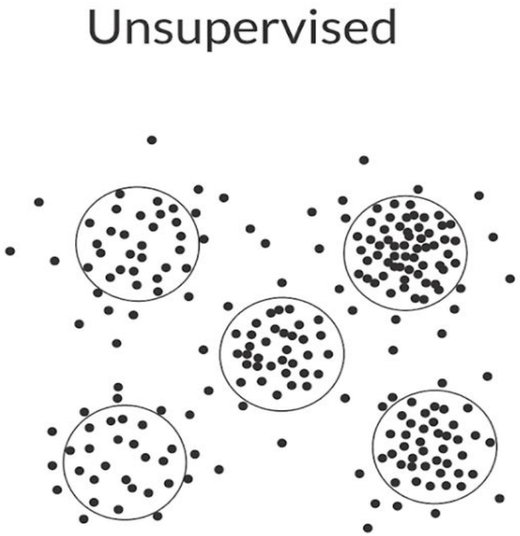

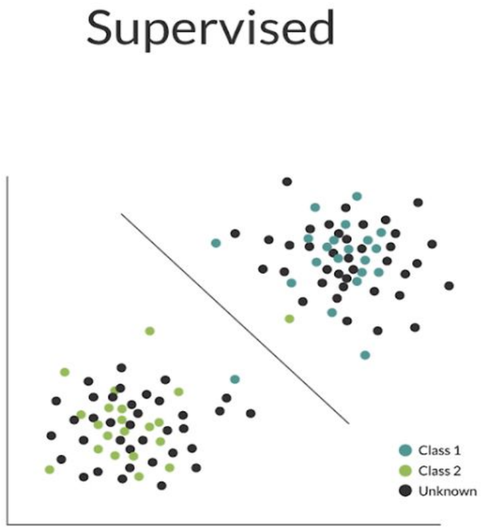

5. Unsuperviesed Anomaly Detection

Isolation Forest

- 각 관측치를 고립시키는 것은 이상치보다 정상 데이터보다 쉽다.

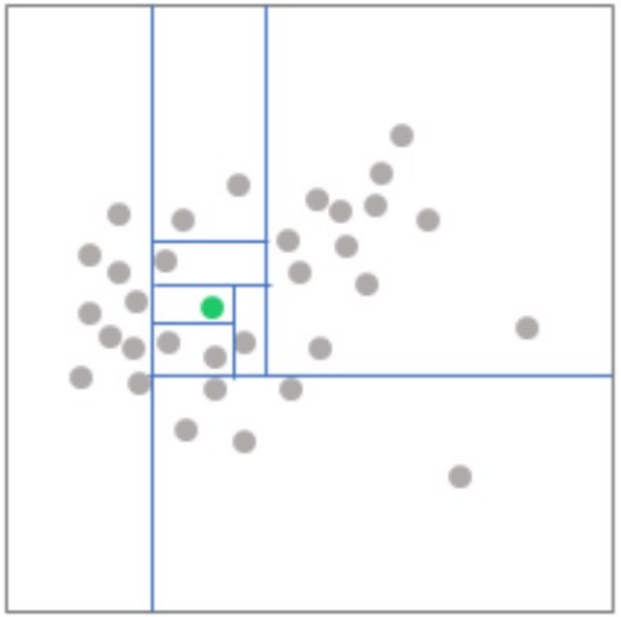

(1) 정상 데이터를 분리하는 경우

약 7번의 split 필요

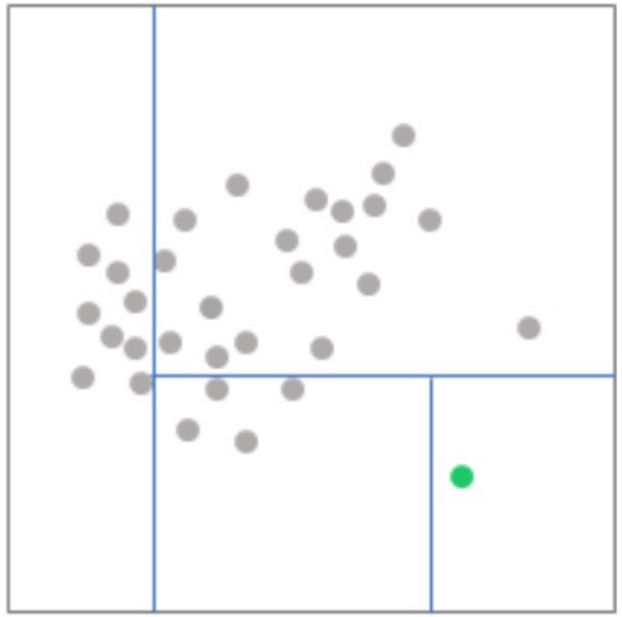

(2) 이상치를 분리하는 경우

약 3번의 split 필요

5. Unsuperviesed Anomaly Detection

Isolation Forest

- iTree를 여러 번 반복하여 앙상블

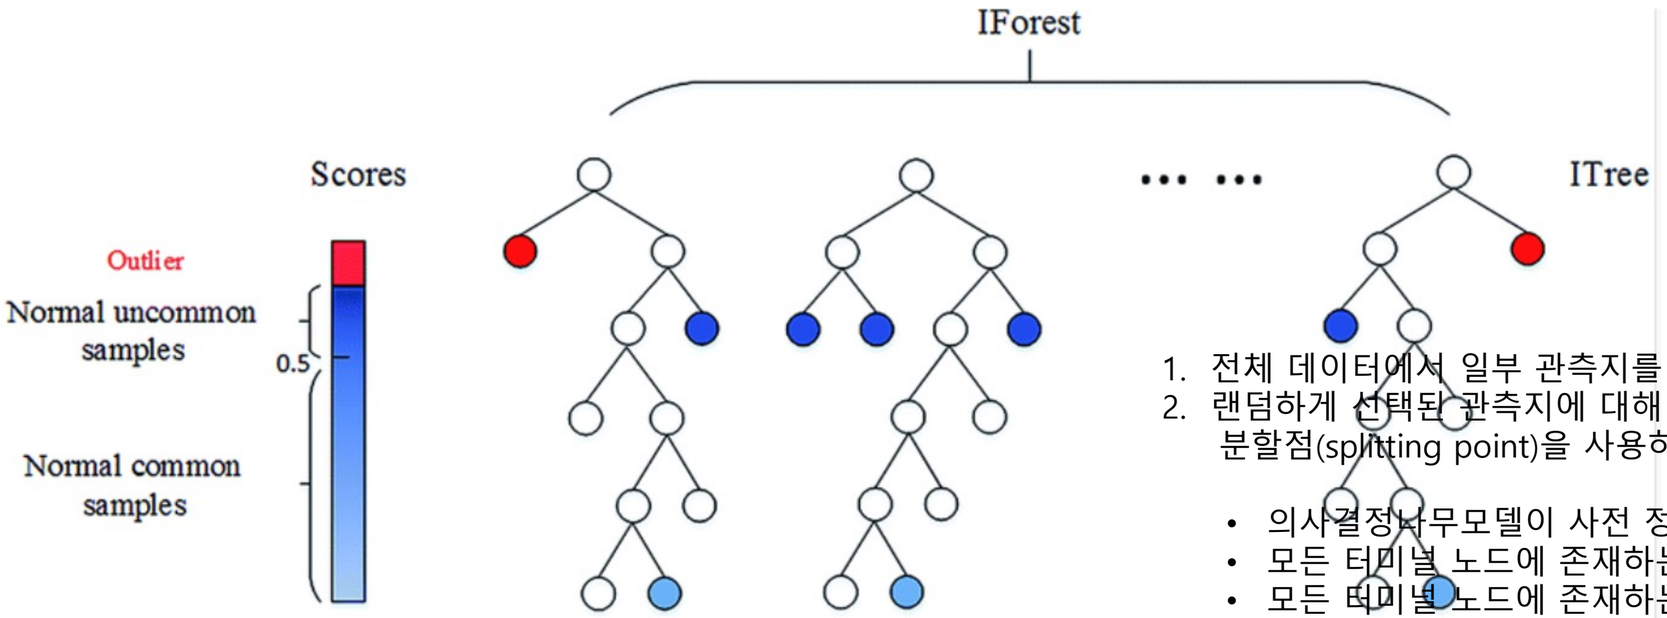

1. 전체 데이터에서 일부 관측지를 랜덤하게 선택
2. 랜덤하게 선택된 관측지에 대해 임의의 변수(Splitting variable)와 분할점(splitting point)을 사용하여 조건을 만족할 때까지 이진분할 진행
   - 의사결정나무모델이 사전 정의된 깊이에 도달
   - 모든 터미널 노드에 존재하는 관측치가 1개씩 존재
   - 모든 터미널 노드에 존재하는 관측치들이 같은 입력변수

3. 위와 같은 과정으로 여러개의 Itree를 구축
4. Itree마다 각 관측지의 Path length(분리 횟수)를 저장
5. 각 관측치의 평균 path length를 기반으로 Anomly score(이상치 스코어를 계산 및 이상

5. Unsuperviesed Anomaly Detection

Isolation Forest

- Scoring

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}}$$

•$h(x)$: 해당 관측치의 경로길이
•$E(h(x))$: 모든 iTree에서 해당 관측치에 대한 평균 경로길이
•$c(n)$: $h(x)$를 nomalise하기 위한 값으로, *iTree*의 평균 경로 길이. (*iTree*는 *Binary Search Tree*와 동일한 구조이기 때문에, $c(n)$값을 쉽게 구한다고 함.)

$E(h(x))$에 따른 Score 값을 보면, 아래와 같습니다.
1.관측치 x가 전체 경로길이의 평균과 유사(= 정상 데이터) : $E(h(x)) \rightarrow c(n)$, $s \rightarrow 0.5$
2.관측치 x가 이상치 : $E(h(x)) \rightarrow 0$, $s \rightarrow 1$
3.관측치 x의 최대 경로길이 : $E(h(x)) \rightarrow n-1$, $s \rightarrow 0$
즉, **Score는 0 ~ 1 사이에 분포되며, 1에 가까울 수록 이상치일 가능성이 크고 0.5 이하이면 정상데이터**로 판단할 수 있습니다.

5. Unsuperviesed Anomaly Detection

Isolation Forest

- Sklearn.ensemble 모듈의 IsolationForest 함수 사용

```
IsolationForest
IsolationForest(max_samples=100, random_state=0)
```

parameters	Description
n_estimators	나무 개수, default = 100
max_samples	각 기본 추정기를 학습할 때 x에서 샘플링할 샘풀 개수, default ='auto'
contamination	데이터셋 내 이상치 비율, default = 'auto
max_features	각 기본 추정기를 학습할 때 x에서 샘플링할 특성의 개수, default = 1.0

https://github.com/scikit-learn/scikit-learn/blob/6a0838c41/sklearn/ensemble/_iforest.py#L54

5. Unsuperviesed Anomaly Detection

One-Class SVM

- 하나의 클래스로 이루어진 데이터에 대해서 정상데이터와 이상치를 나투는 평면을 찾는 비지도 학습 알고리즘
- 원점을 기준으로 Hyper plane을 나눈다. -> SVM과의 차이점

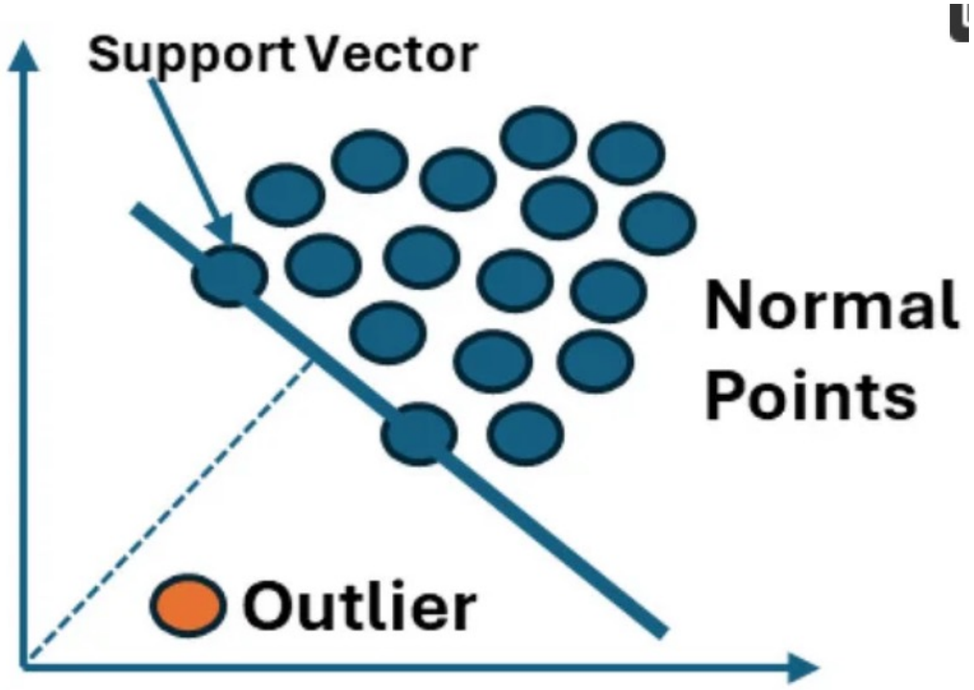

5. Unsuperviesed Anomaly Detection

One-Class SVM

- 하나의 클래스로 이루어진 데이터에 대해서 정상데이터와 이상치를 나투는 평면을 찾는 비지도 학습 알고리즘
- 원점을 기준으로 Hyper plane을 나눈다. -> SVM과의 차이점

1) $k(x,y) = (\Phi(x) \cdot \Phi(y))$

2) $min \frac{1}{2}||w||^2 + \frac{1}{v \cdot m} \sum_i \xi_i - \rho$

3) $w \cdot \Phi(x_i) \geq \rho - \xi_i,\ \xi_i \geq 0$

4) $\min_a \frac{1}{2} \sum_{ij} a_i a_j k(x_i . y_i)$

5) $f(x) = sign\left(\sum_i a_i k(x_i, x) - \rho\right)$

5. Unsuperviesed Anomaly Detection

One-Class SVM

- Sklearn.svm 모듈의 OneclassSVM 함수 사용

```
from sklearn.svm import OneClassSVM
```

```
class sklearn.svm.OneClassSVM(*, kernel='rbf', degree=3,
gamma='scale', coef0=0.0, tol=0.001, nu=0.5, shrinking=True,
cache_size=200, verbose=False, max_iter=-1)
```

parameter	discription
kernel	사용할 커널의 함수 종류를 지정하는 파라미터, default ='rbf'
degree	Kernel ='poly' 사용시, 차수를 결정, default = 'poly'
gamma	Kernel ='rbf' or 'poly' or 'sigmoid' 일 경우 커널에서 사용되는 커널 계수 , default = 'scale'
cofe0	Kernel ='poly' , 'sigmoid' 커널에서만 사용됨, default = '0.0'
tol	최적화 과정에서의 수렴 조건(오차 허용 범위) , default = 1e-3(0.001)
nu	훈련 오류의 상한과 서포트 벡터 개수의 하한을 설정, default = 0.5
shrinking	수축 휴리스틱(Shrinking Heuristic) 사용 여부, default =True
Cathe_size	커널 캐시 크기 (MB 단위) , default = 200MB
max_iter	학습 중 반복 횟수 제한, default =-1

5. Unsuperviesed Anomaly Detection

ElipticEnvelope

- 데이터를 타원형(elliptical) 분포로 가정하고 MCD알고리즘을 사용하여 Roubust convariance matirx를 추정

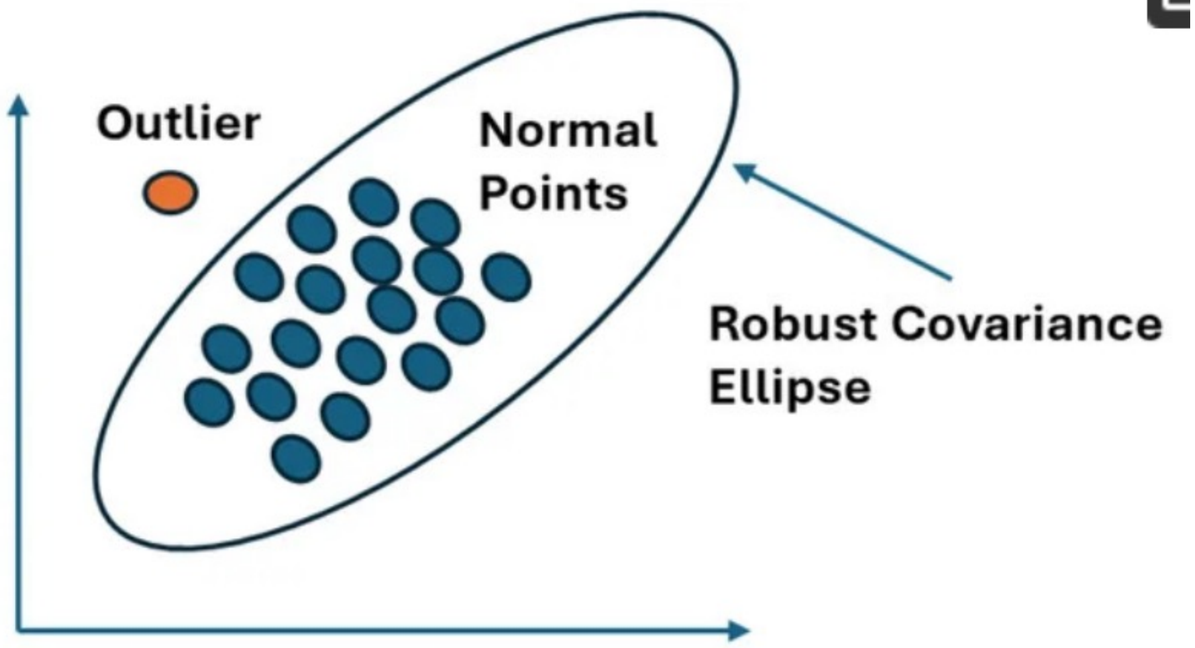

5. Unsuperviesed Anomaly Detection

ElipticEnvelope

- MCD(Minimum Covariance Determinant) 알고리즘
  - 이상치의 영향을 최소화하며 데이터의 대표적인 구조를 찾아내는 방식을 사용
- Robust covariance

$$MD(x) = \sqrt{(x-\bar{x})^T S^{-1}(x-\bar{x})}$$

5. Unsuperviesed Anomaly Detection

ElipticEnvelope

- Sklearn.convariance 모듈의 EllipticEnvelope 함수 사용

```
from sklearn.covariance import EllipticEnvelope
model = EllipticEnvelope(contamination=0.1)  # 10%를 이상치로 가정
model.fit(X_train_scaled)
```

parameters	Description
store_precision	추정된 정밀도를 저장할지 여부를 지정, default = 'bool'
assume_centered	**True**이면, 강건한 위치(location) 및 공분산(covariance) 추정값의 지원(support)을 계산한 후, 데이터를 중앙값으로 정규화하지 않고 공분산을 다시 추정 이는 평균이 0과 거의 같지만 정확히 0이 아닌 데이터에서 유용. **False**이면, 추가적인 처리 없이 FastMCD 알고리즘을 사용하여 직접 강건한 위치 및 공분산을 계산
support_fraction	원시 MCD추정값의 지원에 포함될 데이터의 포인트 비율을 설정 ,default = 'None'
contamination	데이터 세트의 이상치 비율 설정 (0<contamination <0.5)

https://scikit-learn.org/0.15/modules/generated/sklearn.covariance.EllipticEnvelope.html

5. Unsuperviesed Anomaly Detection

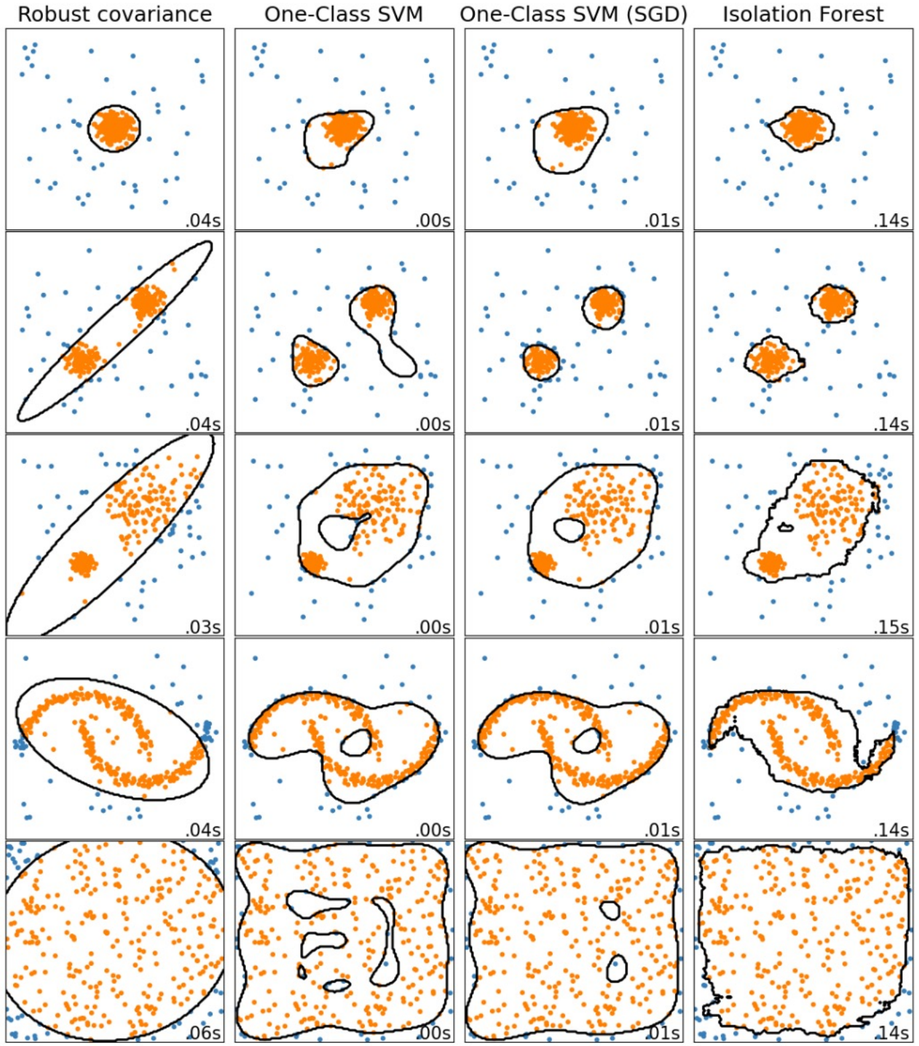

Q & A

감사합니다